UNIVERSIDAD FRANCISCO DE VITORIA

Facultad de Derecho, Empresa y Gobierno

Grado en ADE y Business Analytics

INGENIERÍA DEL DATO

Comparativa de riesgo y rentabilidad entre banca tradicional y tech financiero (2015–2024)

Juan Lantero de la Osa

Trabajo de Fin de Grado

Curso 2025–2026

Índice

1. Origen de los datos 3
1.1 Entidades seleccionadas 4

2. Descripción inicial del dataset 5
2.1 Variables del dataset original 5
2.2 Valores nulos identificados 6

3. Limpieza y transformación 7
3.1 Eliminación de filas vacías 7
3.2 Conversión de tipos de dato e interpolación 7
3.3 Tratamiento de valores nulos 7
3.4 Variables eliminadas y justificación 8
3.5 Actualización de fuentes y cambio de valores 8
3.6 Nueva variable: Subperiodo 9

4. Análisis exploratorio 10
4.1 Estadísticos descriptivos por grupo 10
4.2 Visualización: Rentabilidad acumulada 10
4.3 Visualización: Volatilidad media por empresa 11
4.4 Visualización: Rentabilidad media por subperiodo 12
4.5 Visualización: Máximo Drawdown por empresa 12

5. Análisis de series temporales 13
5.1 Evolución de la volatilidad 13
5.2 Evolución del Sharpe ratio 13
5.3 Evolución de la Beta 14

6. Dataset final y almacenamiento 15
6.1 Resumen del dataset final 15
6.2 Variables finales 15
6.3 Proceso ETL resumido 16

1. Origen de los datos

El punto de partida de este trabajo es la construcción de un dataset propio, elaborado manualmente a partir de tres fuentes de datos públicas. La decisión de construirlo desde cero en lugar de utilizar repositorios ya existentes responde a la necesidad de tener un conjunto de datos homogéneo, en la misma divisa, con el mismo periodo temporal y con las variables financieras ya calculadas de forma consistente entre todas las empresas.

Las tres fuentes utilizadas son:

- **FRED (Federal Reserve Economic Data):** FRED (Federal Reserve Economic Data): se descargó la serie IRLTLT01DEM156N, que recoge el rendimiento mensual del bono alemán a 10 años. Esta serie se utiliza como tasa libre de riesgo en el cálculo del Sharpe ratio y del exceso de rentabilidad. Se eligió el bono alemán en lugar de otros instrumentos por ser la referencia de mayor calidad crediticia dentro de la eurozona y la más utilizada en la literatura financiera europea. Los datos de FRED se presentan como rendimientos anualizados en porcentaje, por lo que se dividieron entre 1.200 para convertirlos a tasa mensual decimal.
- **Investing.com:** Investing.com: se descargó la rentabilidad mensual del índice EUROSTOXX 50, utilizado como benchmark de mercado para el cálculo de la Beta. Se eligió este índice frente al S&P 500 por coherencia con el enfoque europeo del análisis y con la denominación en euros de todo el dataset.
- **Yahoo Finance:** Yahoo Finance: se descargaron los precios históricos mensuales de cierre ajustados por dividendo de las 10 empresas del estudio. El ajuste por dividendo es relevante porque permite calcular la rentabilidad real del accionista, no solo la variación de precio. Para las empresas cotizadas en dólares (las cinco tech financiero), los precios se convirtieron a euros utilizando el tipo de cambio EUR/USD mensual histórico, garantizando la comparabilidad con los bancos europeos.

La combinación de estas tres fuentes permite construir un dataset autocontenido que cubre el periodo enero 2015 - diciembre 2024, con 120 observaciones por empresa y 1.200 filas en total. Todas las variables se expresan en la misma escala, lo que hace posible comparar directamente métricas de riesgo y rentabilidad entre bancos europeos y empresas tech financiero americanas.

1.1 Entidades seleccionadas

El dataset recoge datos de diez empresas divididas en dos grupos:

Grupo	Empresa	País	Ticker	Divisa origen
Banca tradicional	BBVA	España	BBVA.MC	EUR
Banca tradicional	Santander	España	SAN.MC	EUR
Banca tradicional	BNP Paribas	Francia	BNP.PA	EUR
Banca tradicional	Deutsche Bank	Alemania	DBK.DE	EUR
Banca tradicional	HSBC	Reino Unido	HSBA.L	EUR
Tech financiero	Fiserv Inc.	EE.UU.	FI	USD → EUR

Tech financiero	Fidelity National Information Services	EE.UU.	FIS	USD → EUR
Tech financiero	Global Payments Inc.	EE.UU.	GPN	USD → EUR
Tech financiero	Intuit Inc.	EE.UU.	INTU	USD → EUR
Tech financiero	Visa Inc.	EE.UU.	V	USD → EUR

El grupo de tech financiero está formado por empresas consolidadas de tecnología aplicada a servicios financieros: procesadores de pagos, proveedores de infraestructura tecnológica para bancos y desarrolladores de software financiero. No son neobancos ni startups digitales puras, sino empresas con décadas de historia y grandes capitalizaciones de mercado.

2. Descripción inicial del dataset

Antes de aplicar ninguna transformación, se analiza el estado original del dataset tal como se recibe de las fuentes. Este análisis previo es necesario para identificar los problemas de calidad que hay que corregir y para documentar el punto de partida del proceso de limpieza.

2.1 Variables del dataset original

El dataset original contiene 19 columnas organizadas en tres bloques: identificadores de la empresa, variables de precio y rentabilidad, y variables de riesgo. A continuación se describe cada una:

Variable	Tipo	Descripción
Fecha	datetime	Primer día de cada mes (ej. 2015-01-01)
Año	float64	Año de la observación
Mes	float64	Mes de la observación (1-12)
Bank	object	Grupo: 'Bank' o 'Tech Financiero'
Empresa	object	Nombre de la empresa
País	object	País de cotización principal
Ticker	object	Símbolo bursátil
Divisa Origen	object	Divisa original antes de convertir a EUR
Precio_acc_EUR	object*	Precio mensual de cierre ajustado en euros
Rentab_Mensual	object*	Rentabilidad mensual: (P_t - P_t-1) / P_t-1
Rentab_Acumulada	object*	Rentabilidad acumulada desde enero 2015
Exceso	object*	Rentab_Mensual - Risk Free Rate
Sharpe ratio	object*	Rentabilidad ajustada al riesgo (rolling 12m)
Risk Free Rate	object*	Bono alemán 10 años mensual (FRED)
Drawdowns	object*	Caída desde máximo histórico hasta cada mes
EUROSTOXX_Ret	object*	Rentabilidad mensual del EUROSTOXX 50
Beta	object*	Sensibilidad al mercado (rolling 12m)
Alpha	object*	Rentabilidad extra sobre CAPM (rolling 12m)
Volatilidad_Mensual	object*	Desviación estándar rolling 12m de rentabilidad

*Las variables marcadas con asterisco están almacenadas como tipo object en lugar de float64. Esto ocurre porque el archivo Excel original contiene fórmulas en lugar de valores calculados, y pandas lee las fórmulas como texto al importar el archivo. La conversión a tipo numérico es una de las transformaciones principales del proceso de limpieza.

2.2 Valores nulos identificados

El análisis inicial de nulos revela dos situaciones bien diferenciadas que requieren tratamientos distintos:

Variable	Nulos	% sobre total	Tipo de nulo
Fecha, Año, Mes, Empresa...	8	0.66%	Filas completamente vacías
Precio_acc_EUR, Rentab_Mensual...	7	0.58%	Filas completamente vacías
Sharpe ratio	117	9.69%	Estructural (ventana rolling)
Beta	117	9.69%	Estructural (ventana rolling)
Alpha	117	9.69%	Estructural (ventana rolling)
Volatilidad_Mensual	115	9.52%	Estructural (ventana rolling)

Los 8 nulos en las variables identificadoras corresponden a 8 filas completamente vacías que se eliminan durante la limpieza. Los nulos en Sharpe ratio, Beta, Alpha y Volatilidad mensual son de naturaleza estructural: estas variables se calculan mediante una ventana rolling de 12 meses, por lo que los primeros 11 meses de cada empresa no pueden calcularse por definición. Estos nulos no representan un error en los datos ni se imputan.

3. Limpieza y transformación

A partir del análisis inicial se diseña un proceso de limpieza y transformación que aborda los problemas identificados de forma ordenada. Se documenta cada decisión tomada y su justificación, de acuerdo con las buenas prácticas de ingeniería del dato.

3.1 Eliminación de filas vacías

Se eliminan las 8 filas que no contienen ningún dato de empresa ni de periodo. Estas filas son un artefacto del archivo Excel original y no aportan ninguna información. Tras esta operación el dataset pasa de 1.208 a 1.200 filas, que es el número esperado: 10 empresas × 120 meses.

3.2 Conversión de tipos de dato

La transformación más relevante del proceso es la conversión de las variables numéricas de tipo object a float64. Las 11 columnas afectadas son: Precio_acc_EUR, Rentab_Mensual, Rentab_Acumulada, Exceso, Sharpe ratio, Risk Free Rate, Drawdowns, EUROSTOXX_Ret, Beta, Alpha y Volatilidad_Mensual.

El proceso utiliza pd.to_numeric() con errors='coerce', que convierte los valores numéricos correctamente y transforma en NaN cualquier valor que no pueda convertirse. Esto permite que la operación sea segura incluso si hubiera algún valor no numérico mezclado en la columna.

Adicionalmente, la columna Drawdowns tenía un espacio en blanco al final de su nombre ('Drawdowns '), que impedía su referencia directa en el código. Se renombra correctamente mediante rename().

Previamente a la conversión, se verificó la presencia de valores no numéricos aislados en cada serie. En los casos en que hubieran aparecido valores puntuales imposibles de convertir (por ejemplo, celdas con texto) la estrategia habría sido aplicar interpolación lineal mediante interpolate(method='linear'), que estima el valor faltante como la media ponderada de los valores adyacentes en la serie temporal. En el dataset final no se encontraron valores de este tipo, por lo que la interpolación no fue necesaria.

3.3 Tratamiento de valores nulos

Como se anticipó en el análisis inicial, los nulos de Sharpe ratio, Beta, Alpha y Volatilidad mensual son estructurales y no se eliminan ni imputan. Existe una razón clara: estas variables se calculan sobre una ventana rolling de 12 meses, por lo que no es posible obtener un valor estadísticamente válido con menos de 12 observaciones.

> *La interpolación de estos nulos habría sido metodológicamente incorrecta. Imputar los primeros 11 meses de Sharpe ratio con una media móvil o interpolación lineal introduciría sesgos artificiales en los primeros valores de cada serie, que podrían distorsionar el análisis comparativo posterior. La decisión de mantener los nulos es una elección deliberada, no una omisión.*

Tras la limpieza, la distribución de nulos queda de la siguiente forma:

Variable	Nulos tras limpieza	Justificación
Sharpe ratio	110	11 meses × 10 empresas (rolling 12m)
Beta	110	11 meses × 10 empresas (rolling 12m)
Alpha	110	11 meses × 10 empresas (rolling 12m)
Volatilidad_Mensual	109	11 meses × 10 empresas (rolling 12m)*
Resto de variables	0	Limpieza completada

3.4 Variables eliminadas

Durante la construcción del dataset se tomaron decisiones explícitas sobre qué variables incluir y cuáles eliminar. Las tres columnas descartadas son:

- **Beta Real:** columna prácticamente vacía con solo 10 valores sobre 1.200 posibles. El 99.2% de sus valores son nulos, lo que la hace inútil para el análisis. Además se solapa conceptualmente con la variable Beta, que sí está correctamente calculada.
- **Max_Precio_Hist**: columna auxiliar que almacena el precio máximo histórico hasta cada fecha. Fue necesaria para calcular el Drawdown en Excel mediante la fórmula =(Precio_actual - MAX(precios_anteriores)) / MAX(precios_anteriores), pero una vez calculado el Drawdown no aporta valor analítico propio.
- **Exceso:** variable derivada directamente de Rentab_Mensual - Risk Free Rate. Al tener ya las dos variables originales en el dataset, mantener su diferencia es redundante. El exceso de rentabilidad se puede calcular en cualquier momento durante el análisis.

3.5 Actualización de fuentes

Además de las transformaciones descritas, el proceso de limpieza incluyó la sustitución de dos columnas con datos de fuentes más adecuadas:

- **Risk Free Rate:** Risk Free Rate: la versión original del dataset utilizaba una tasa libre de riesgo con valores negativos que no correspondían al bono alemán a 10 años. Se sustituyó por los datos oficiales de FRED (serie IRLTLT01DEM156N), que recogen el rendimiento mensual promediado del mes completo. Los valores de FRED se expresan como rendimiento anualizado en porcentaje y se convierten a tasa mensual decimal dividiendo entre 1.200 (÷100 para pasar a decimal y ÷12 para pasar a mensual).

  La conversión de precios de dólares a euros constituye un cambio de valores en el sentido estricto del término: cada observación de precio de las cinco empresas americanas fue transformada multiplicando el precio en USD por el tipo de cambio EUR/USD mensual histórico correspondiente. Esta transformación implica que los valores numéricos del dataset no coinciden con los precios originales descargados de Yahoo Finance, sino con su equivalente en euros. Se documentó el tipo de cambio utilizado en cada mes para garantizar la trazabilidad del proceso.
- **Benchmark de mercado:** Benchmark de mercado: la versión original utilizaba la rentabilidad mensual del S&P 500 para calcular la Beta. Se sustituyó por el EUROSTOXX

50, que es el índice de referencia europeo y es más coherente con el análisis de empresas cotizadas principalmente en Europa y con el dataset denominado en euros.

3.6 Nueva variable: Subperiodo

Se añade la variable Subperiodo, que clasifica cada observación mensual en una de las tres fases económicas del periodo analizado:

Subperiodo	Periodo	Observaciones	Característica principal
Tipos bajos	Ene 2015 – Dic 2019	600	BCE con tipos negativos, abundante liquidez
COVID-19	Ene 2020 – Dic 2021	240	Shock pandémico, volatilidad extrema y recuperación
Subida de tipos	Ene 2022 – Dic 2024	360	BCE sube tipos agresivamente para controlar inflación

Esta segmentación está justificada en el anteproyecto con base en la literatura financiera y es fundamental para el análisis comparativo posterior: permite evaluar cómo responde cada grupo de empresas ante entornos macroeconómicos distintos, que es precisamente la pregunta central del trabajo.

4. Análisis exploratorio

Una vez completado el proceso de limpieza, se realiza un análisis exploratorio del dataset para entender la distribución y comportamiento de las variables clave. El análisis se estructura en dos partes: estadísticos descriptivos comparativos y visualizaciones.

4.1 Estadísticos descriptivos por grupo

La siguiente tabla recoge los principales estadísticos descriptivos de las variables de análisis, separados por grupo. Los valores de Sharpe ratio, Beta, Alpha y Volatilidad excluyen los primeros 11 meses de cada empresa, donde estas variables no están disponibles.

Variable	Métrica	Banca tradicional	Tech financiero
Rentabilidad mensual	Media	0.43%	1.34%
Rentabilidad mensual	Desv. típica	9.47%	7.07%
Rentabilidad mensual	Mínimo	-37.16%	-21.60%
Rentabilidad mensual	Máximo	+59.59%	+23.74%
Volatilidad mensual	Media	9.14%	6.85%
Sharpe ratio	Media	0.033	0.253
Sharpe ratio	Desv. típica	0.300	0.300
Drawdown máximo	Mínimo	-79.33%	-67.88%
Beta	Media	1.254	0.717
Alpha	Media	-0.001	+0.010

Los estadísticos revelan diferencias importantes entre grupos. El tech financiero presenta una rentabilidad media mensual tres veces superior a la banca (1.34% frente a 0.43%), un Sharpe ratio casi ocho veces mayor (0.253 frente a 0.033) y una volatilidad menor (6.85% frente a 9.14%). Los bancos, por su parte, presentan mayor sensibilidad al mercado europeo (Beta 1.254 frente a 0.717) y drawdowns máximos más profundos.

Estos patrones son consistentes con la literatura financiera revisada en el anteproyecto. Beck (2021) y Bollaert (2021) documentan que las empresas de tech financiero presentan mejores ratios de rentabilidad ajustada al riesgo en entornos de tipos bajos, exactamente lo que reflejan los estadísticos globales del periodo 2015-2024.

4.2 Visualización: Rentabilidad acumulada

El gráfico de rentabilidad acumulada es el más revelador del análisis exploratorio. Las cinco líneas naranjas (tech financiero) se separan progresivamente de las cinco azules (banca) desde 2016, alcanzando multiplicadores de hasta 6x al cierre del periodo. Intuit Inc. acumula una rentabilidad del 643% frente al -27% de Santander.

Esta diferencia no es homogénea dentro del grupo tech: Fiserv Inc. (+42%) se aproxima al nivel de los bancos mejor posicionados (BBVA +31%), mientras que Intuit, FIS y Visa multiplican ampliamente. La dispersión dentro del grupo tech es mayor que dentro del grupo bancario.

> *El gráfico de rentabilidad acumulada utiliza precios ajustados por dividendo, lo que refleja la rentabilidad total del accionista. Esta es la métrica relevante para la comparación, no el precio de cotización sin ajustar.*

4.3 Visualización: Volatilidad media por empresa

Los cuatro bancos europeos con mayor volatilidad son Deutsche Bank, BBVA, BNP Paribas y Santander, todos por encima del 8% mensual. HSBC es el banco menos volátil (6.4%), situándose en el rango del tech financiero. Las cinco empresas tech presentan volatilidades entre el 4.7% (Visa) y el 8.6% (Global Payments).

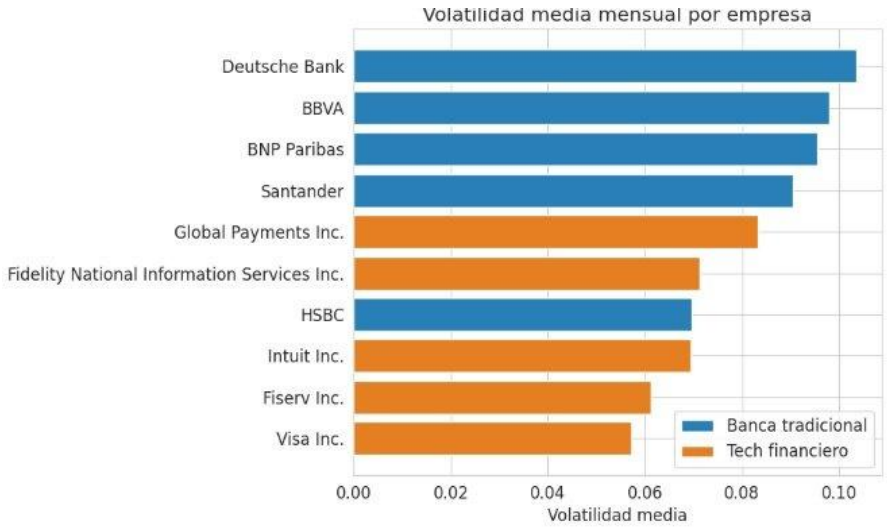

El resultado de que los bancos europeos sean más volátiles que las tech financiero americanas en este periodo específico se debe a la combinación de tipos de interés negativos que destruían márgenes

bancarios, escándalos regulatorios (Deutsche Bank), exposición a mercados emergentes (BBVA con Turquía, Santander con Latinoamérica) y el shock del COVID-19, que golpeó desproporcionadamente al sector financiero europeo. Las tech financiero, con modelos de negocio basados en comisiones por volumen y sin balance bancario, mostraron mayor estabilidad.

4.4 Visualización: Rentabilidad media por subperiodo

El análisis por subperiodo muestra un patrón que anticipa los resultados del análisis estadístico posterior. En tipos bajos (2015-2019), la banca tiene una rentabilidad media ligeramente positiva (1.06% mensual) mientras el tech muestra un 0.72%. Durante el COVID (2020-2021) ambos grupos convergen en torno al 0.6-1.05% mensual. El cambio más llamativo se produce en la subida de tipos (2022-2024): la banca sube al 1.40% mensual mientras el tech cae al 0.64%.

Este patrón es coherente con la teoría: los bancos se benefician de tipos altos porque amplían sus márgenes de intermediación, mientras que las techs, cuyas valoraciones dependen del descuento de flujos de caja futuros, se ven penalizadas cuando la tasa de descuento sube.

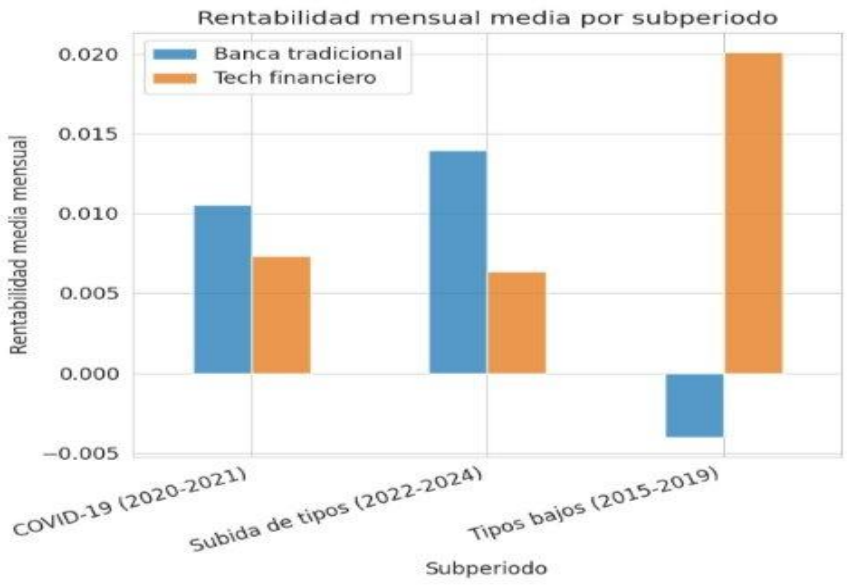

4.5 Visualización: Máximo Drawdown por empresa

El máximo drawdown refleja la caída máxima desde el precio más alto alcanzado hasta el punto más bajo posterior. Los resultados muestran que los bancos europeos sufrieron caídas mucho más profundas que las tech financiero: Deutsche Bank llegó a caer un 79.3% desde su máximo dentro del periodo analizado, seguido de Santander (-75.7%) y BBVA (-73.3%).

Las tech financiero americanas presentan drawdowns significativamente menores, con Fiserv (-26%) y Visa (-28%) como las más resistentes. Esta diferencia refleja que las tech tienen modelos de negocio con menores riesgos sistémicos: no tienen balance bancario, no están sujetas a provisiones por crédito y no dependen de tipos de interés para generar ingresos.

5. Análisis de series temporales

El análisis exploratorio estático se complementa con un análisis de la evolución temporal de las métricas de riesgo, que permite identificar cómo cambia el comportamiento de los dos grupos a lo largo de los tres subperiodos económicos.

5.1 Evolución de la volatilidad

La evolución de la volatilidad media mensual por grupo confirma el patrón de los estadísticos agregados, pero añade información sobre la dinámica temporal. En el periodo de tipos bajos (2015-2019) la banca mantiene una volatilidad consistentemente superior al tech, situándose entre el 7% y el 11% frente al 4-7% del tech.

El impacto del COVID-19 es visible con claridad: en marzo-abril 2020 la volatilidad de la banca se dispara hasta casi el 18%, mientras el tech sube solo hasta el 10-11%. La diferencia de impacto es llamativa y consistente con la mayor exposición de los bancos al riesgo de crédito durante la pandemia.

A partir de 2022, las volatilidades convergen progresivamente. En 2023 y 2024 ambos grupos se sitúan en rangos similares (6-10%), lo que anticipa la convergencia estadística que se observa en el análisis del dato.

5.2 Evolución del Sharpe ratio

La evolución del Sharpe ratio es el indicador que mejor captura el diferencial de calidad entre grupos. Durante el periodo de tipos bajos, las tech mantienen un Sharpe positivo y estable (0.2-0.6), mientras la banca oscila entre valores negativos y moderadamente positivos, con un Sharpe medio cercano a cero. Esto refleja que los tipos negativos destruían la rentabilidad ajustada al riesgo de la banca.

En el COVID, ambos grupos se ven afectados negativamente en un primer momento, pero las tech recuperan más rápido y vuelven a niveles positivos antes que la banca. El cambio más significativo se produce en 2022: con la subida de tipos, el Sharpe de la banca mejora notablemente y en 2023-2024 supera al del tech de forma consistente. Este es el hallazgo clave que el análisis estadístico posterior confirma con significancia estadística.

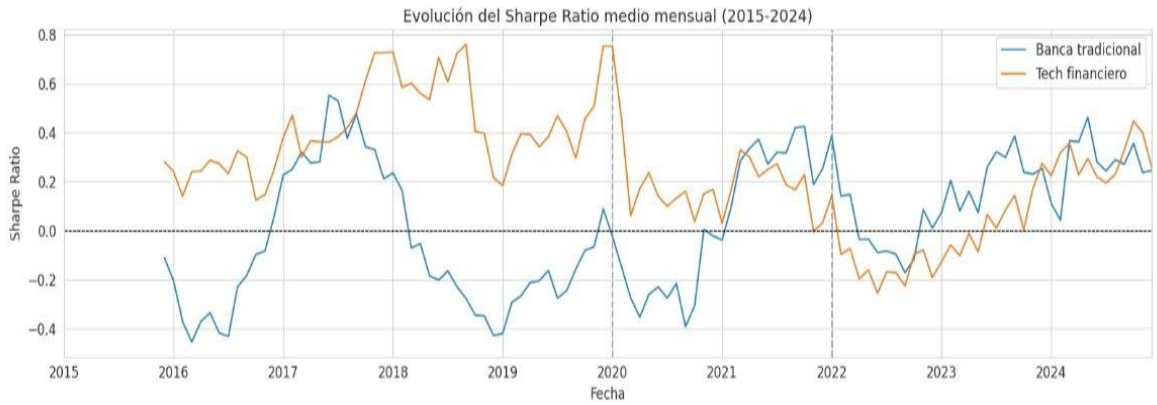

5.3 Evolución de la Beta

La evolución de la Beta requiere una interpretación cuidadosa. La Beta se calcula en este trabajo respecto al EUROSTOXX 50, que es un índice europeo. Para los bancos europeos, esta referencia es la más adecuada. Para las tech financiero americanas, la Beta respecto al EUROSTOXX es menor no porque sean menos volátiles en términos absolutos, sino porque tienen menor correlación con el mercado europeo.

> *Limitación metodológica: La Beta de las empresas tech financiero americanas calculada respecto al EUROSTOXX 50 no es directamente comparable con la Beta de los bancos europeos. Su correlación natural es mayor con el S&P 500. Este resultado debe interpretarse con esta limitación presente: una Beta baja del tech respecto al EUROSTOXX no implica que sean activos defensivos en términos absolutos, sino que están menos correlacionados con el índice europeo.*

Con esta limitación presente, la evolución temporal muestra que la Beta de la banca permaneció consistentemente por encima de 1 durante gran parte del periodo (especialmente 2016-2021), lo que indica que amplificaba los movimientos del EUROSTOXX. A partir de 2022, ambas Betas convergen hacia 1, reflejando la normalización de los mercados.

6. Dataset final y almacenamiento

Una vez completado el proceso de ingeniería del dato, el dataset queda almacenado como DATOS_TFG_LIMPIO.xlsx en Google Drive, listo para su uso en el Análisis del Dato. A continuación se documenta el estado final del dataset.

6.1 Resumen del dataset final

Característica	Valor
Nombre del archivo	DATOS_TFG_LIMPIO.xlsx
Número de filas	1.200
Número de columnas	20
Periodo	Enero 2015 – Diciembre 2024
Frecuencia	Mensual
Empresas	10 (5 bancos + 5 tech financiero)
Observaciones por empresa	120 meses
Nulos en variables de precio/rentabilidad	0
Nulos estructurales (rolling 12m)	109-110 por variable

6.2 Variables finales

Variable	Tipo	Nulos	Fuente
Fecha	datetime64	0	Yahoo Finance
Año	int64	0	Derivada
Mes	int64	0	Derivada
Bank	object	0	Manual
Empresa	object	0	Yahoo Finance
País	object	0	Manual
Ticker	object	0	Yahoo Finance
Divisa Origen	object	0	Manual
Precio_acc_EUR	float64	0	Yahoo Finance
Rentab_Mensual	float64	0	Calculada
Rentab_Acumulada	float64	0	Calculada
Exceso	float64	0	Calculada
Sharpe ratio	float64	110	Calculada (rolling 12m)
Risk Free Rate	float64	0	FRED
Drawdowns	float64	0	Calculada

EUROSTOXX_Ret	float64	0	Investing.com
Beta	float64	110	Calculada (rolling 12m)
Alpha	float64	110	Calculada (rolling 12m)
Volatilidad_Mensual	float64	109	Calculada (rolling 12m)
Subperiodo	object	0	Derivada

6.3 Proceso ETL resumido

El proceso de extracción, transformación y carga (ETL) se documenta de forma resumida:

Fase	Acción	Resultado
Extracción	Descarga de precios mensuales de Yahoo Finance	10 series temporales en CSV/Excel
Extracción	Descarga de bono alemán de FRED	Serie IRLTLT01DEM156N (120 meses)
Extracción	Descarga de EUROSTOXX 50 de Investing.com	Rentabilidades mensuales (120 meses)
Transformación	Conversión USD → EUR de empresas americanas	Precios homogéneos en euros
Transformación	Cálculo de métricas financieras en Excel	Rentab., Sharpe, Beta, Alpha, Drawdown, Volatilidad
Transformación	Sustitución RFR por datos FRED	Tasa libre de riesgo correcta
Transformación	Sustitución benchmark por EUROSTOXX 50	Benchmark coherente con análisis europeo
Limpieza	Eliminación de 8 filas vacías	Dataset de 1.200 observaciones
Limpieza	Conversión de object a float64	11 columnas numéricas correctamente tipadas
Limpieza	Renombrado de Drawdowns (espacio)	Nombre correcto para referencia en código
Enriquecimiento	Creación de variable Subperiodo	Clasificación temporal en 3 fases
Carga	Almacenamiento como DATOS_TFG_LIMPIO.xlsx	Dataset listo para análisis